

AI 知识库构建指南

一、概述

本文档是 knowledge-architecture 项目的示例 PDF，用于演示 PDF 文档解析的两种方法。页面包含可提取的文字内容，后续页面还包含嵌入的图片和矢量图形。

二、知识库核心流程

构建 AI 知识库通常包括以下步骤：

1. 文档收集 — 收集各类格式的文档（PDF、Word、Markdown 等）
2. 文档解析 — 将文档内容提取为纯文本
3. 文本分块 — 将长文本切分为语义连贯的片段
4. 向量化 — 使用 Embedding 模型将文本片段转为向量
5. 存储与索引 — 将向量存入向量数据库
6. 检索与生成 — 基于用户问题检索相关片段，交给 LLM 生成回答


（本页为纯文字内容，可被 pdf-parse 和 LangChain PDFLoader 提取）

三、文档解析与图片

本页包含一张嵌入的 PNG 光栅图片。文字解析工具（如 pdf-parse）只能提取文字，无法提取图片内容。这是纯文字提取方法的固有限限。


图 1：嵌入式光栅图片示例（由 pngjs 动态生成的渐变 PNG）

注意：上图是光栅图片，pdf-parse 和 LangChain PDFLoader 均无法提取图片中的内容。如需提取图片，需要使用 pdfjs-dist 等更高级的库。



四、向量化与检索

本页包含矢量图形（矩形、圆形、三角形）和文字说明。矢量图形与光栅图片一样，无法被文字解析工具提取。



上图展示