

AI 知识库工具与模型对比

本文档包含两个表格，用于测试 PDF 转 Markdown 时表格结构的保留情况。pdf-parse 提取表格时会丢失行列结构，文本按阅读顺序输出为纯文本。

一、PDF 解析工具对比

工具名称	支持格式	图片提取	表格识别	开源免
pdf-parse	PDF	不支持	不支持	是
LangChain PDFLoader	PDF	不支持	不支持	是
pdfjs-dist	PDF	支持	部分支持	是
Apache Tika	PDF/Word/Excel	支持	部分支持	是
Unstructured	PDF/Word/HTML	支持	支持	是
Camelot	PDF	不支持	支持	是

表 1：常见 PDF 解析工具能力对比

二、Embedding 模型对比

以下是常用嵌入模型的参数对比，用于知识库向量化阶段选型参考：

模型名称	维度	最大 Token	提供商	中文支持
text-embedding-v3	1024	8192	阿里云	优秀
text-embedding-3-small	1536	8191	OpenAI	良好
text-embedding-3-large	3072	8191	OpenAI	良好
bge-large-zh-v1.5	1024	512	智源研究院	优秀
m3e-base	768	512	Moka AI	优秀
gte-large-zh	1024	512	达摩院	优秀

表 2：
常用 Embedding
模型参数对比

三、 文本分块策略说明

文本分块是知识库构建的关键步骤。常见的分块策略包括：固定

长度
分块
（按
字符
数切
割）
、语
义分
块
（按
段落
或句
子边
界切
割）
、滑
动窗
口分
块
（相
邻块
有重
叠部
分）
和递
归分
块
（先
按大
段落
切，
再按
句子
细分
）。
选择
合适
的分
块策

略直接影
响检索准
确率和生
成质量。